



**Hochschule
Bonn-Rhein-Sieg**

*University
of Applied Sciences*

Fachbereich Informatik
Department of Computer Sciences

Abschlussarbeit

Studiengang Bachelor Informatik

Entwurf und Evaluation eines fehlertoleranten Job-Processing in Java

von

Max Urfei

Erstprüfer: Prof. Dr. Andreas Hackelöer

Zweitprüfer: M. Sc. Moritz Balg

eingereicht am TT.MM.YYYY

Inhaltsverzeichnis

Abkürzungsverzeichnis	iii
Abbildungsverzeichnis	iv
1 Einleitung	1
1.1 Motivation	1
1.2 Problemstellung	1
1.3 Zielsetzung	2
1.4 Hypothesen	3
1.5 Aufbau der Arbeit	3
2 Grundlagen	4
2.1 Grundlagen der Hintergrundverarbeitung	4
2.1.1 Synchrone vs. Asynchrone Verarbeitung	4
2.1.2 Ausführungssemantiken	5
2.1.3 Background Job-Processing	6
2.2 Konsistenz und konkurrierende Verarbeitung	7
2.2.1 ACID	8
2.2.2 Transaktionsgrenzen	9
2.2.3 Locking	10
2.3 Fehlertoleranz und Wiederherstellung	10
2.3.1 Retry-/Backoff-Strategien	10
2.3.2 Fehlerklassifikationen	10
2.3.3 Recovery	10
2.3.4 Idempotenz	11
2.4 Zustandsmodellierung mittels State Machines	11
2.5 Stand der Technik	11
3 Methodik	13
3.1 Literaturrecherche	13
3.2 Ergebniserzeugung	13
4 Anforderungen	14
4.1 Funktionale Anforderungen	14
4.2 Qualitätsanforderungen	14
4.3 Zusicherungen	14
5 Umsetzung	15
5.1 Architektur und Design	15
5.2 Implementierung	17
5.2.1 Technologie-Stack	17

5.2.2	Zentrale Code-Entscheidungen	17
6	Evaluation	18
6.1	Fehlerszenarien	18
6.2	Durchführung	18
6.3	Ergebnisse	18
7	Diskussion	19
7.1	Gewonnene Erkenntnisse	19
7.2	Einschränkungen und Grenzen der Arbeit	19
8	Fazit und Ausblick	20
	Literaturverzeichnis	21

Abkürzungsverzeichnis

ACID Atomicity, Consistency, Isolation, Durability. 8, 9

CRUD Create, Read, Update, Delete. 1

REST Representational State Transfer. 6

UI User Interface. 6

Abbildungsverzeichnis

1 Einleitung

1.1 Motivation

In modernen Softwaresystemen stellt die Verarbeitung von Hintergrundjobs einen zentralen Bestandteil vieler Backend-Architekturen dar (Kleppmann 2017, Kap. 10). Zahlreiche Geschäftsprozesse, darunter die Generierung von Reports, der Import großer Datenmengen, periodische Abrechnungsläufe oder das Versenden asynchroner Benachrichtigungen, erfordern eine Verarbeitung, die entkoppelt vom synchronen Request-Response-Zyklus stattfindet. Insbesondere in industrienahen und sicherheitskritischen Anwendungen, etwa im Bereich der luftfahrttechnischen Wartungsdokumentation, müssen solche Prozesse nicht nur funktional korrekt ablaufen, sondern darüber hinaus zuverlässig, nachvollziehbar und fehlertolerant sein.

1.2 Problemstellung

In der Praxis können bei der Verarbeitung von Hintergrundjobs jederzeit Teilausfälle auftreten. Prozesse können während der Verarbeitung unerwartet terminieren, Datenbankverbindungen können kurzzeitig unterbrochen werden oder identische Anfragen werden zum Beispiel infolge von clientseitigen Wiederholungsversuchen mehrfach an das System übermittelt oder Ergebnisse bzw. Antworten gehen verloren (Kleppmann 2017, Kap. 8). Ohne geeignete Mechanismen führen derartige Szenarien zu inkonsistenten Systemzuständen. Beispielsweise verbleiben Jobs im Status „laufend“, obwohl kein Worker sie mehr aktiv verarbeitet, Ergebnisse werden doppelt erzeugt oder Aufträge gehen vollständig verloren.

Bestehende Frameworks und Bibliotheken, etwa Quartz Scheduler (Terracotta Inc. (Hrsg.) 2026) oder Spring Batch (Broadcom Inc. (Hrsg.) 2026), adressieren Teilaspekte der Hintergrundverarbeitung, setzen jedoch voraus, dass grundlegende Architekturentscheidungen bewusst und korrekt getroffen werden. So muss unter anderem entschieden werden, wie sichergestellt wird, dass ein Job nach einem Prozessabsturz nicht verloren geht, wie verhindert wird, dass zwei Worker denselben Job gleichzeitig verarbeiten, wie das System doppelte Aufträge erkennt und redundante Ergebnisse vermeidet und wie es sich bei kurzzeitigen Datenbankausfällen verhält. Keine der genannten Lösungen beantwortet diese Fragen vollständig. Sie erfordern vielmehr ein durchdachtes Zusammenspiel aus einem persistenten Statusmodell, klar definierten Transaktionsgrenzen, geeigneten Locking-Strategien, Mechanismen zur Vermeidung doppelter Ausführung sowie Retry- und Backoff-Policies. Die zentrale Herausforderung liegt darin, diese Mechanismen so zu entwerfen und zu kombinieren, dass das System definierte Zusicherungen unter allen relevanten Fehlerszenarien einhält.

Die beschriebene Problematik ist von hoher praktischer und industrieller Relevanz. Nahezu jedes Backend-System, das über einfache Create, Read, Update, Delete (CRUD)-Operationen hinausgeht, muss eine Form der zuverlässigen Hintergrundverarbeitung mit-

tels Transaktionen implementieren (Richardson 2018, Kap. 4). Fehler in diesem Bereich führen zu Datenverlust, inkonsistenten Geschäftszuständen sowie unnötigem manuellem Eingriff und können insbesondere in regulierten Domänen wie der Luftfahrt Compliance-Verstöße nach sich ziehen. Auch im Kontext von Cloud-nativen Architekturen ist dieses Thema relevant. Horizontale Skalierung, Container-Neustarts und kurzzeitige Netzwerkunterbrechungen können auftreten und müssen behandelt werden. Daher bilden die in dieser Arbeit behandelten Konzepte auch die Grundlage für den zuverlässigen Betrieb von Backend-Systemen in Cloud-Umgebungen. Trotz dieser Relevanz existiert wenig praxisorientierte und zugleich evaluierte Literatur, die den gesamten Entwurfsprozess eines solchen Systems, von der Anforderungsdefinition über die Architekturentscheidungen bis hin zum systematischen Fehlervalidierung, nachvollziehbar dokumentiert und empirisch überprüft.

Daraus ergibt sich die dieser Arbeit zugrundeliegende Hauptforschungsfrage:
Welche Architekturmechanismen und Entwurfsentscheidungen sind notwendig, um in einem Java/Spring-basierten Job-Processing-Backend definierte Konsistenzzusicherungen unter typischen Teilausfallszenarien nachweisbar einzuhalten?

Zur Beantwortung dieser Frage werden folgende Teilfragen untersucht:

- TF1: Welche Zusicherungen muss das System gewährleisten, damit Jobs stets korrekt und ohne Inkonsistenzen verarbeitet werden?
- TF2: Welchen Beitrag leisten Idempotenz, Retry-Strategien und Dead-letter-Handling zur Robustheit unter definierten Fehlerszenarien?
- TF3: Wie müssen Transaktionen und Locking-Strategien genutzt werden, damit bei paralleler Arbeit mehrerer Worker keine Doppelverarbeitung oder inkonsistenten Zustände entstehen?
- TF4: Wie lässt sich sicherstellen, dass Jobs nach einem unerwarteten Prozessabbruch korrekt wiederaufgenommen werden, ohne dass Aufträge verloren gehen?

1.3 Zielsetzung

Ziel dieser Arbeit ist der Entwurf, die prototypische Implementierung und die Evaluation eines fehlertoleranten Job-Processing-Backends auf Basis von Java und Spring. Dabei soll herausgearbeitet werden, welche Architekturmechanismen erforderlich sind, damit Hintergrundjobs auch bei Teilausfällen zuverlässig, korrekt und nachvollziehbar verarbeitet werden und definierte Konsistenzzusicherungen eingehalten werden.

Konkret verfolgt die Arbeit folgende Teilziele:

- TZ1: Definition von Zusicherungen: Es sollen präzise Korrektheitsbedingungen formuliert werden, die das System zu jedem Zeitpunkt einhalten muss, unabhängig davon, welche Fehler auftreten. Dazu zählen unter anderem, dass kein Job doppelt erfolgreich abgeschlossen wird, dass kein Job dauerhaft verloren geht und dass Statusübergänge ausschließlich dem definierten Zustandsmodell folgen.

- TZ2: Architekturentwurf: Es soll eine Architektur entworfen werden, die persistente Job-States, Idempotenz, Retry-Strategien sowie ein nachvollziehbares Statusmodell umfasst. Architekturentscheidungen sollen explizit dokumentiert und begründet werden.
- TZ3: Prototypische Implementierung: Die entworfene Architektur soll als funktionsfähiger Prototyp umgesetzt werden, der die definierten Zusicherungen unter realistischen Bedingungen einhält.
- TZ4: Evaluation unter Fehlerbedingungen: Es soll nachgewiesen werden, dass das System seine Zusicherungen auch bei gezielt herbeigeführten Teilausfällen nicht verletzt.

1.4 Hypothesen

Auf Basis der Forschungsfrage und der Zielsetzung werden folgende Hypothesen formuliert, deren Überprüfung im Rahmen der Implementierung und insbesondere der Evaluation erfolgt.

- H1: Durch die Kombination eines persistenten Statusmodells mit transaktionsbasiertem Locking und Idempotenz-Mechanismen lässt sich ein System entwerfen, das auch bei unerwarteten Prozessabbrüchen keine Jobs verliert und keine doppelten Ergebnisse erzeugt.
- H2: Retry-Strategien mit exponentiellem Backoff in Verbindung mit einer Fehlerklassifikation (transient vs. permanent) erhöhen die Robustheit des Systems gegenüber kurzzeitigen Infrastrukturausfällen, ohne dabei die definierten Zusicherungen zu verletzen.
- H3: Die definierten Zusicherungen lassen sich durch automatisierte Tests mit gezielter Fehlerinjektion reproduzierbar überprüfen und nachweisen.

1.5 Aufbau der Arbeit

2 Grundlagen

Orientierung ca. 8-12 Seiten

2.1 Grundlagen der Hintergrundverarbeitung

Hintergrundverarbeitung dient dazu, zeitintensive oder ressourcenintensive Aufgaben vom synchronen Request-Response-Zyklus zu entkoppeln. Gleichzeitig entstehen daraus jedoch auch einige Herausforderungen: In verteilten Umgebungen sind Teilausfälle, Timeouts und kurzzeitige Unterbrechungen üblich, sodass nicht ohne entsprechende Mechanismen davon ausgegangen werden kann, dass eine angestoßene Verarbeitung vollständig und genau einmal ausgeführt wird. Insbesondere kann bei Kommunikationsabbrüchen oder Wiederholungsversuchen unklar bleiben, ob eine Operation bereits verarbeitet wurde oder ob sie erneut angestoßen werden muss (Kleppmann 2017, Kap. 8). Vor diesem Hintergrund werden in den folgenden Abschnitten grundlegende Konzepte vorgestellt, die eine Entkopplung der Verarbeitung ermöglichen und die Basis für robuste Hintergrundverarbeitung bilden.

2.1.1 Synchrone vs. Asynchrone Verarbeitung

In Backend-Systemen lässt sich Kommunikation und Verarbeitung bezüglich der zeitlichen Kopplung zwischen synchronem und asynchronem Verhalten unterscheiden: Bei synchroner Verarbeitung nach dem Request-Response-Stil wartet der Aufrufer auf eine Antwort auf die Anfrage und blockiert gegebenenfalls bevor er fortfährt. Bei asynchroner Verarbeitung wird die Bearbeitung des Auftrags vom Zeitpunkt des Erhalts entkoppelt. Der Aufrufer initiiert die Arbeit, blockiert jedoch nicht und kann auch während des Wartens auf eine Antwort weiter arbeiten (Richardson 2018, Kap. 3.1.1).

Um Nachrichtenverluste zu reduzieren und Lastspitzen auszugleichen, verwenden asynchrone Systeme in der Praxis häufig einen Puffer. Durch das sogenannte „queueing“ (Kleppmann 2017, Kap. 11, Abschnitt „Message brokers“), bei dem erhaltene Anfragen zur späteren Ausführung in den Puffer geschrieben werden, wird unter anderem die Asynchronität erreicht. Ein Produzent sendet eine Nachricht an einen Zwischenspeicher, beispielsweise einen Message Broker, und wartet in der Regel nur auf das Acknowledgment, dass die Nachricht zwischengespeichert wurde, nicht jedoch auf die Verarbeitung oder das Ergebnis (Kleppmann 2017, Kap. 11, Abschnitt „Messaging Systems“). Die so erreichte Entkopplung hat gleichzeitig den Vorteil, dass die Verarbeitung der Anfrage unabhängig von der Verbindung zwischen Produzent und Konsument wird. Im Gegensatz dazu kann bei synchronen Systemen bei Verbindungsabbrüchen oder Timeouts unklar bleiben, ob eine Anfrage den Server erreicht hat oder bereits verarbeitet wurde. Genau dieses Problem adressieren Message Broker: Falls ein Konsument temporär nicht verfügbar ist oder während der Verarbeitung ausfällt, können Message Broker trotzdem für die At-Least-Once-Semantik (vgl. Kapitel 2.1.2) sorgen (Kleppmann 2017, Kap. 11, Abschnitt „Ack-

nowledgments and redelivery“). Die synchrone Request-Response-Kommunikation bietet demgegenüber eine unmittelbare Rückmeldung über Erfolg oder Fehler einer Operation, setzt jedoch voraus, dass Client und Server während der gesamten Interaktion verfügbar sind (Richardson 2018, Kap. 3.4).

Die asynchrone Verarbeitung bildet damit die Grundlage für die Hintergrundverarbeitung, indem die Entkopplung genutzt wird, um Aufgaben unabhängig vom ursprünglichen Aufruf auszuführen und gleichzeitig die Robustheit und Skalierbarkeit des Systems zu erhöhen (Newman 2026, Kap. 8, Abschnitt „Why Use A Message Broker?“).

2.1.2 Ausführungssemantiken

In verteilten Systemen führen potenziellen Prozessabstürze und Teilausfälle dazu, dass Aufträge verloren gehen oder der Verarbeitungszustand einer Aufgabe unklar sein kann. Um zu beschreiben, was Systeme aufgrund ihres Entwurfs und ihrer Mechanismen zur Fehlertoleranz bezüglich Auslieferung beziehungsweise Ausführung garantieren, werden grundsätzlich drei fundamentale Ausführungssemantiken unterschieden, die Newman (2026, Kap. 8 Abschnitt „Types of Delivery Guarantees“) vor dem Hintergrund der Auslieferung wie folgt definiert. Im Kontext von Job-Processing sind diese Semantiken zur Nachrichtenzustellung analog auf die Ausführung der Jobs anwendbar.

At-Least-Once

Ein Konsument erhält die Nachricht mindestens einmal. Bei der Auslieferung bestätigt der Konsument über ein Acknowledge das Ankommen der Nachricht. Sofern das Acknowledge beim Absender eingeht, kann dieser die Nachricht löschen, bleibt diese Bestätigung innerhalb eines Zeitfensters jedoch aus, z.B. weil die Nachricht oder das Acknowledge verloren geht, wird die Nachricht erneut zugestellt. Dieser Fall wird Redelivery genannt. Dieses Verfahren verhindert Datenverlust, birgt jedoch das Risiko von Duplikaten, für den Fall, dass die Nachricht ankommt, aber das Acknowledge verloren geht und es infolgedessen zur Redelivery kommt. Einschränkend sei hier gesagt, dass die Zustellung nicht garantiert werden kann, wenn der Konsument bei keinem Zustellversuch verfügbar ist.

At-Most-Once

Ein Konsument erhält die Nachricht maximal einmal. Der Produzent schickt die Nachricht ab und erwartet keine Empfangsbestätigung. Eine erneute Zustellung findet unter keinen Umständen statt. Dadurch werden Duplikate strikt ausgeschlossen, jedoch muss ein potenzieller Datenverlust zugunsten besserer Latenzen hingenommen werden.

Exactly-Once

Diese Semantik garantiert, dass eine Nachricht genau einmal beim Konsumenten ankommt. In der Praxis ist das nur schwer zu realisieren, da beispielsweise nicht klar sein kann, ob ein Acknowledgement nur noch nicht angekommen, oder schon verloren gegangen ist. Viele Umsetzungen beruhen daher darauf, dass entsprechende Mechanismen

sowohl beim Produzent, als auch Konsument implementiert werden. Eine Variante zur Umsetzung ist die Approximation über eine Kombination von At-Least-Once beim Produzent und Idempotenz beim Konsument. Die Garantie bezieht sich somit nicht auf die physische Zustellung einer Nachricht, sondern auf die Wirkung ihrer Verarbeitung. Eine Nachricht kann mehrfach zugestellt werden, solange ihre Verarbeitung nur einmal wirksam wird.

2.1.3 Background Job-Processing

Aufbauend auf den Konzepten der asynchronen Verarbeitung (vgl. Kapitel 2.1.1) bezeichnet das Background Job-Processing die Ausführung von Aufgaben außerhalb des Request-Response-Zyklus. Hierbei werden fachliche Operationen als eigenständige Arbeitseinheiten (Jobs) modelliert und zeitlich entkoppelt verarbeitet.

In der Softwarearchitektur existieren verschiedene etablierte Entwurfsmuster zur Umsetzung einer solchen Infrastruktur, wie beispielsweise das Queue-Based Load Leveling Pattern (Microsoft Corporation (Hrsg.) 2026b). Dieses Muster besteht aus drei funktionalen Kernkomponenten:

- **Der Produzent:** Erzeugt einen Job und gibt diesen weiter an den Job-Store. Das kann zum einen direkt durch das User Interface (UI) geschehen, oder die UI ruft einen Endpoint auf, der den Job über eine synchrone Schnittstelle, wie z.B. Representational State Transfer (REST), entgegen nimmt. In letzterem Fall fungiert der Service hinter dem Endpoint als Produzent. Dessen Aufgabe besteht darin, den Auftrag zu validieren und an die Persistenzschicht zu übergeben, woraufhin der synchrone Request-Response-Zyklus für den Client sofort beendet wird. Jobs können aber nicht nur durch solche Event-driven Trigger ausgelöst werden, sondern auch durch Schedule-driven Trigger. Dabei erfolgt die Ausführung eines Jobs periodisch oder zu vordefinierten Zeitpunkten, z.B. über durch einen Cron-Trigger (Microsoft Corporation (Hrsg.) 2026a).
- **Der Job-Store:** Speichert die Jobs für den Zeitraum zwischen Erstellung und endgültiger Beendigung zwischen. Für die Umsetzung existieren verschiedene Varianten, beispielsweise als Message Queue oder relationale Datenbank. Diese Realisierungsmöglichkeiten bieten jeweils spezifische Vor- und Nachteile und die Nutzung. Die Auswahl des passenden Ansatzes sollte daher durch die Qualitätsanforderungen an das System, wie z.B. Durchsatz oder Akzeptanz einzelner verlorener Jobs, begründet werden (Kleppmann 2017, Kap. 11).
- **Der Worker:** Autonome Komponente, die als Konsument fungiert. Sobald der Worker über freie Systemressourcen verfügt, kann er einen wartenden Job aus dem Job-Store beanspruchen und führt diesen aus (Microsoft Corporation (Hrsg.) 2026b).

Durch eine solche Architektur können Background Jobs als „fire and forget“-Operationen (Microsoft Corporation (Hrsg.) 2026a) implementiert werden. Sie laufen asynchron in einem vom Client isolierten Prozess, sodass deren Verarbeitungszeit keinerlei unmittelbare

Auswirkung auf die Reaktionszeit oder Verfügbarkeit der primären Benutzeroberfläche hat (Microsoft Corporation (Hrsg.) 2026a). Außerdem ermöglicht dieses Konzept das Abfangen von Lastspitzen und flexiblere Skalierung (Microsoft Corporation (Hrsg.) 2026b).

Die Zuweisung von Jobs an Worker kann grundsätzlich über unterschiedliche Modelle erfolgen. Beim Push-Modell weist eine zentrale Komponente Aufgaben aktiv freien Worker-Instanzen zu. Beim Pull-Modell fragen Worker eigenständig neue Aufgaben aus dem Job-Store ab. Beide Ansätze unterscheiden sich hinsichtlich Komplexität, Skalierbarkeit und Koordinationsaufwand (Kleppmann 2017, Kap. 11 Abschnitt „Transmitting Event Streams“).

Da die Verarbeitung zeitlich entkoppelt erfolgt, müssen Informationen über offene und bereits bearbeitete Jobs über den Lebenszyklus einzelner Prozesse hinweg erhalten bleiben. Hierfür ist eine persistente Speicherung des Verarbeitungszustands erforderlich, da das System nach einem Ausfall in der Lage sein muss, den zuletzt bekannten Zustand zu rekonstruieren und die Verarbeitung fortzusetzen (Kleppmann 2017, Kap. 11, Abschnitt „Rebuilding state after a failure“). Grundlagen zur Zustandshaltung werden in Kapitel 2.4 betrachtet.

Werden mehrere Worker parallel betrieben, entsteht die Herausforderung der konkurrierenden Verarbeitung. Ohne geeignete Koordinationsmechanismen könnten mehrere Instanzen denselben Job gleichzeitig beanspruchen oder widersprüchliche Statusänderungen durchführen. Die hierfür relevanten Konzepte werden in Kapitel 2.2 behandelt.

Darüber hinaus müssen Background-Processing-Systeme mit Teilausfällen umgehen können. Prozesse können während der Ausführung terminieren, externe Systeme zeitweise nicht erreichbar sein oder Kommunikationsfehler auftreten. Das System muss daher entscheiden können, ob eine Verarbeitung erneut durchgeführt, fortgesetzt oder endgültig beendet werden soll (Microsoft Corporation (Hrsg.) 2026a). Konzepte zur Fehlerbehandlung und Wiederherstellung werden in Kapitel 2.3 vorgestellt.

Ebenfalls kritisch ist die Frage, wie sichergestellt werden kann, dass Wiederholungen oder Mehrfachausführungen nicht zu inkonsistenten Ergebnissen führen. Da der tatsächliche Verarbeitungszustand nach einem Fehler nicht immer eindeutig bestimmbar ist, müssen Systeme geeignete Konsistenzmechanismen bereitstellen. Hierzu zählen insbesondere Transaktionskonzepte und Verfahren zur kontrollierten Wiederaufnahme von Verarbeitungen, die in Kapitel 2.3 behandelt werden.

2.2 Konsistenz und konkurrierende Verarbeitung

Bei der Verarbeitung von Daten durch mehrere parallel arbeitende Prozesse entsteht die Herausforderung, dass konkurrierende Zugriffe auf gemeinsame Ressourcen zu inkonsistenten Zuständen führen können. Ohne geeignete Mechanismen können Änderungen verloren gehen, widersprüchliche Zustände entstehen oder mehrere Prozesse dieselben Daten gleichzeitig verändern (Saake, Heuer und Sattler 2018, Kap. 13.1.2).

Im Kontext von Background Job-Processing tritt dieses Problem insbesondere dann auf, wenn mehrere Worker-Instanzen parallel auf denselben Jobbestand zugreifen. Versuchen sie ohne geeignete Synchronisationsmechanismen denselben Job zu beanspruchen

oder konkurrierende Statusänderungen durchzuführen, können Race Conditions entstehen (Kleppmann 2017, Kap. 7 Abschnitt „Isolation“). Insbesondere bei Pull-basierten Architekturen, bei denen die Jobverteilung nicht durch eine Orchestrierungskomponente realisiert wird, muss eine solche ungewollte Doppelbeanspruchung explizit verhindert werden (Kleppmann 2017, Kap. 7 Abschnitt „Isolation“). Die Gewährleistung konsistenter Zustände stellt daher eine zentrale Anforderung an Systeme mit paralleler Verarbeitung dar. Die hierfür etablierten Konzepte und Mechanismen werden in den folgenden Abschnitten vorgestellt.

2.2.1 ACID

Zur Vereinfachung der Gewährleistung konsistenter Zustände bei parallelen Zugriffen existiert das Konzept der Transaktionen. Diese fassen mehrere Operationen zu einer logischen Einheit zusammen, deren Ausführung nach außen als zusammenhängender Vorgang erscheint (Kleppmann 2017, Kap. 7). Im Kontext persistenter Datenhaltung werden von Transaktionen typischerweise die vier zentralen Eigenschaften Atomicity, Consistency, Isolation, Durability (ACID) gefordert (Saake, Heuer und Sattler 2018, Kap. 13.1.1):

Atomicity Die Atomarität stellt sicher, dass eine Transaktion entweder vollständig oder gar nicht ausgeführt wird. Tritt während der Ausführung ein Fehler auf, werden sämtliche bis dahin vorgenommenen Änderungen verworfen, sodass keine partiellen Zwischenzustände bestehen bleiben.

Consistency Die Konsistenz beschreibt die Eigenschaft, dass eine erfolgreich abgeschlossene Transaktion die Daten von einem gültigen Zustand in einen anderen gültigen Zustand überführt. Dabei müssen definierte Integritätsbedingungen erhalten bleiben. Kleppmann (2017, Kap. 7 Abschnitt „Consistency“) weist darauf hin, dass die Einhaltung solcher fachlichen Invarianten in der Verantwortung der Anwendung liegt und nicht durch das Datenbanksystem garantiert werden kann.

Isolation Die Isolation gewährleistet, dass parallel ausgeführte Transaktionen sich nicht gegenseitig beeinflussen. Aus Sicht einer Transaktion soll die Ausführung so erscheinen, als würde sie allein auf dem Datenbestand arbeiten. Dadurch können Race Conditions und andere Nebenläufigkeitsprobleme vermieden werden.

Durability Die Dauerhaftigkeit garantiert, dass die Ergebnisse einer erfolgreich abgeschlossenen Transaktion auch nach Systemabstürzen oder anderen Fehlern dauerhaft erhalten bleiben.

Im Kontext von Background Job-Processing sind insbesondere die Eigenschaften der Atomarität und Isolation von Bedeutung. Während die Atomarität verhindert, dass Statusänderungen eines Jobs nur teilweise durchgeführt werden, bildet die Isolation die Grundlage für die koordinierte Verarbeitung gemeinsamer Datenbestände durch mehrere parallel arbeitende Worker-Instanzen. Die relevanten Konzepte zum Erreichen dieser Eigenschaften werden in den folgenden Abschnitten näher betrachtet.

2.2.2 Transaktionsgrenzen

Während ACID die theoretischen Garantien einer Transaktion definiert, bestimmt die Festlegung von Transaktionsgrenzen, welche konkreten Datenbankoperationen des softwareseitigen Kontrollflusses zu einer unteilbaren, logischen Einheit zusammengefasst werden. Die Festlegung dieser Grenzen steuert, wann eine Datenbanksitzung eine Transaktion initiiert und zu welchem Zeitpunkt die Änderungen final festgeschrieben (Commit) oder im Fehlerfall vollständig verworfen (Rollback) werden (Kudraß 2015, S.250).

Die Wahl geeigneter Transaktionsgrenzen wird zusätzlich dadurch erschwert, dass fachliche und technische Transaktionen nicht zwangsläufig identisch sind. Eine fachliche Transaktion beschreibt eine zusammenhängende Geschäftsoperation, deren Ergebnis aus Sicht der Anwendung als Einheit betrachtet wird. Eine technische Transaktion hingegen bezeichnet die konkrete Transaktion auf der Datenbankebene, welche die ACID-Eigenschaften für die von ihr gekapselten Datenbankoperationen bereitstellt. Während eine fachliche Operation mehrere technische Transaktionen umfassen kann, können innerhalb einer technischen Transaktion auch nur Teilaspekte einer fachlichen Operation verarbeitet werden. Werden die Grenzen falsch gesetzt, können verschiedene Parallelitätsanomalien auftreten (Saake, Heuer und Sattler 2018, Kap. 13.1.2). Ein verbreiteter Ansatz zur Vermeidung dieser Anomalien ist die Verwendung von Sperren, auf die in Kapitel 2.2.3 näher eingegangen wird. Wichtig ist an dieser Stelle, dass die gewählte Transaktionsgrenze direkten Einfluss auf die Dauer von Sperren und die Interaktion mit parallel ausgeführten Transaktionen hat.

Eine Möglichkeit besteht darin, jede Datenbankoperation in einer eigenen Transaktion auszuführen. Dadurch werden Sperren nur für sehr kurze Zeit gehalten, was die Parallelität und den Durchsatz des Systems erhöht. Allerdings können zusammengehörige Änderungen nicht mehr atomar ausgeführt werden. Tritt zwischen mehreren aufeinanderfolgenden Operationen ein Fehler auf, können bereits festgeschriebene Änderungen nicht mehr gemeinsam zurückgesetzt werden. Die betroffenen Daten können dadurch in einen fachlich falschen Zustand überführt werden.

Als naiver Gegenentwurf können die Transaktionsgrenzen entsprechend der fachlichen Transaktion gesetzt werden. Diese Strategie kann jedoch zu langlaufenden Transaktionen führen, welche die Leistungsfähigkeit des Datenspeichers beeinträchtigt. Zum einen halten Transaktionen im Beispiel des 2-Phasen-Sperrprotokolls sämtliche während ihrer Laufzeit akquirierten Sperren bis zum endgültigen Commit oder Rollback aufrecht (Kleppmann 2017, Kap. 7 Abschnitt „Two-Phase Locking (2PL)“). Dadurch steigt die Wahrscheinlichkeit, dass konkurrierende Transaktionen aufeinander warten müssen. Zum anderen können langlaufende Transaktionen die Bereinigung alter Datenversionen verzögern, da diese weiterhin für aktive Transaktionen sichtbar bleiben müssen (The PostgreSQL Global Development Group (Hrsg.) 2026, Kap. 24.1.2). Dies erhöht den Ressourcenbedarf des Datenbanksystems und kann dessen Leistungsfähigkeit beeinträchtigen.

Im Software-Entwurf erfordert das Setzen der Transaktionsgrenzen daher eine kontinuierliche Abwägung zwischen der Systemperformance und dem Schutz vor Datenanomalien. Weit gefasste Transaktionsgrenzen reduziert das Risiko der Entstehung von Inkonsistenzen, blockieren jedoch Systemressourcen und Datensätze. Eng gefasste Grenzen

erhöhen den Durchsatz, können jedoch das Risiko konkurrierender Zugriffe und daraus resultierender Race Conditions erhöhen.

2.2.3 Locking

Optimistisches Locking (Richardson 2018, Kap.6.2) Die konkrete Wirkung von Sperrmechanismen hängt zusätzlich von der gewählten Isolationsstufe des Datenbanksystems ab. Diese bestimmt, welche Änderungen parallel ausgeführter Transaktionen sichtbar sind und welche Anomalien auftreten können. Höhere Isolationsstufen bieten stärkere Konsistenzgarantien, gehen jedoch häufig mit einer geringeren Parallelität einher (Saake, Heuer und Sattler 2018, Kap. 13.1.2).

2.3 Fehlertoleranz und Wiederherstellung

Die Wiederaufnahme darf jedoch nicht zu inkonsistenten Ergebnissen führen, wenn eine Verarbeitung bereits teilweise erfolgt ist und somit Duplikate oder Wiederholungen auftreten (Newman 2026, Kap. 3 Abschnitt „Idempotency“). Statusänderungen und fachliche Datenänderungen müssen folglich über klar definierte Transaktionsgrenzen abgesichert werden, um eine konsistente Weiterbearbeitung nach einem Crash zu gewährleisten (Kleppmann 2017, Kap. 7).

“Reliability”

2.3.1 Retry-/Backoff-Strategien

(Newman 2026, Kap. 3) Daneben muss das System unterscheiden können, ob ein Job tatsächlich noch aktiv bearbeitet wird oder ob er lediglich in einem Zwischenzustand verblieben ist, weil der Worker während der Ausführung unvorhergesehen terminiert ist. Ein weiterer Grundpfeiler des Background Job-Processing ist daher die systematische Fehlerbehandlung und Wiederaufnahme (Kleppmann 2017, Kap. 11 Abschnitt „Acknowledgments and redelivery“). Da Teilausfälle dazu führen können, dass unklar ist, ob ein Verarbeitungsschritt bereits erfolgreich abgeschlossen wurde, wird mit Wiederholungsmechanismen gearbeitet. Hierbei ist eine exakte Fehlerklassifikation relevant, um transiente Fehler (z. B. kurzzeitige Nichterreichbarkeit eines externen Dienstes) über zeitlich gestaffelte Retry-Strategien mit Backoff zu überbrücken und eine Systemüberlastung zu vermeiden, während permanente Fehler direkt zu einem kontrollierten Abbruch führen (Newman 2026, Kap. 3).

(Microsoft Corporation (Hrsg.) 2026a, Abschnitt „Reliability consideration“—> letzter Punkt)

2.3.2 Fehlerklassifikationen

2.3.3 Recovery

Dein „remote datastore“ ist praktisch deine PostgreSQL-Jobtabelle (persistenter Job-Store). Das entspricht dem Ansatz „State remote halten“, was Recovery vereinfacht, aber

Laufzeit/Contention beeinflusst. Dein Worker hat vermutlich lokalen, transienten Zustand während der Verarbeitung (in-memory). Der muss nach Crash nicht „rekonstruiert“ werden, sondern du brauchst Mechanismen wie Lease/Timeout + Retry, um Jobs wieder aufzunehmen. „Replay state from input“ entspricht bei dir am ehesten: Job erneut ausführen (at-least-once) – und genau deshalb brauchst du Idempotenz, weil „replay“ bei Side-Effects sonst doppelte Ergebnisse erzeugt. (Kleppmann 2017, Kap.11 Rebuilding a state failure)

2.3.4 Idempotenz

Wichtig für exactly-once Semantik (Newman 2026, Kap. 8, Abschnitt „Types Of Delivery Guarantees“) (Kleppmann 2017, Kap.11 -> Atomic commit revisited & Idempotence) (Richardson 2018, Kap.3.3.6) Message Broker, um doppelte Nachrichten zu Eliminieren (Richardson 2018, Kap.3.3.6) Einen Message Consumer Idempotent machen (Richardson 2018, Kap.6.1.6)

2.4 Zustandsmodellierung mittels State Machines

Eine architektonische Option besteht darin, den aktuellen Zustand in einem externen Datenspeicher (*Remote Datastore*) zu verwalten.

2.5 Stand der Technik

Für die praktische Umsetzung existieren unterschiedliche Frameworks, die einzelne Aspekte von Background Job-Processing adressieren. Quartz Scheduler bietet trigger- bzw. zeitgesteuertes Scheduling und unterstützt Persistenz sowie Clustering zur koordinierten Ausführung.[Terracotta Inc. 2026] Spring Batch stellt eine Infrastruktur für Batch-Verarbeitung bereit, insbesondere mit Job-/Step-Modell und Persistenz der Ausführungshistorie.[Broadcom Inc. 2026] JobRunr bietet datenbankgestütztes Background Job-Processing in Java mit integriertem Retry-Handling.[Rosoco BV 2026] Temporal stellt eine Workflow-Engine für langlebige, robuste Ausführung bereit, erfordert jedoch einen eigenständigen Serverbetrieb und damit zusätzliche Betriebskomplexität.[Temporal Technologies Inc. 2026] Diese Lösungen verdeutlichen, dass „Background Job-Processing“ in der Praxis nicht allein durch eine Bibliothek gelöst wird, sondern durch Architekturentscheidungen zur Persistenz, zur Nebenläufigkeitskontrolle sowie zur Fehlerbehandlung und Wiederaufnahme.[Kleppmann 2017] Die konkrete Wahl und Kombination dieser Mechanismen hängt von den gewünschten Zusicherungen und den betrachteten Fehlerszenarien ab.[Kleppmann 2017]

hier noch Message Queues ansprechen und warum diese die behandelte Problematik nicht vollständig lösen.

Eventuate Framework (Chris Richardson) als industriellen Referenzpunkt integrieren. - Konzeptionelle Parallele: Nutzt das Transactional Outbox Pattern zur atomaren Kopplung von Fachdaten und Nachricht/Job in einer gemeinsamen ACID-Transaktion (Post-

greSQL). - Technischer Unterschied: Eventuate nutzt primär Change Data Capture (CDC / Log Tailer), um Events an einen externen Broker (z. B. Kafka) zu pushen. - Abgrenzung meiner Arbeit: Ich evaluiere das schlankere, rein datenbankgestützte Pull-Modell via SQL-Polling und 'SKIP LOCKED', um die Betriebskomplexität eines separaten Brokers einzusparen.

3 Methodik

3.1 Literaturrecherche

3.2 Ergebnisgenerierung

4 Anforderungen

4.1 Funktionale Anforderungen

4.2 Qualitätsanforderungen

4.3 Zusicherungen

5 Umsetzung

5.1 Architektur und Design

Einen Message Consumer Idempotent machen (Richardson 2018, Kap.6.1.6) Statusmodell: Consumers may crash at any time, so it could happen that a broker delivers a message to a consumer but the consumer never processes it, or only partially processes it before crashing. In order to ensure that the message is not lost, message brokers use *acknowledgments*: a client must explicitly tell the broker when it has finished processing a message so that the broker can remove it from the queue." (Kleppmann 2017, Kap. 11, Abschnitt „Acknowledgments and redelivery“)

Obwohl das Queue-Based Load Leveling Pattern in der Praxis häufig mit dedizierten Message Brokern implementiert wird, stellt die Verwendung einer relationalen Datenbank wie PostgreSQL als Job-Store für das vorliegende System eine architektonisch bewusste Entscheidung dar. Durch die Nutzung von PostgreSQL-spezifischen Mechanismen wie SKIP LOCKED in Kombination mit vollen ACID-Transaktionsgarantien lässt sich die von Microsoft (2023) geforderte Lastverteilung realisieren, ohne die für die Fehlertoleranz kritische atomare Verknüpfung von Job-Status und Fachdaten aufzugeben. Es wird in dieser Arbeit also nicht direkt ein Message Broker genutzt, sondern ein eigenes System auf Basis einer relationalen Datenbank umgesetzt, was sich funktional stark an den Prinzipien eines Message Brokers orientiert.

„Es ist anzumerken, dass eine verteilte Konsistenz zwischen einem dedizierten Message Broker und einem relationalen Datenspeicher theoretisch auch über ein Two-Phase-Commit-Protokoll (2PC) realisiert werden kann. In der verteilten Softwarearchitektur gilt 2PC jedoch aufgrund des hohen Koordinations- und Netzwerk-Overheads sowie des inhärent blockierenden Verhaltens bei Koordinator-Ausfällen als performanzkritisch und komplex (vgl. Kleppmann 2017, Kap. 9). Die Entscheidung für eine rein datenbankgestützte Architektur auf Basis von PostgreSQL wurde daher bewusst getroffen, um die operationelle Komplexität zu minimieren und eine atomare Verknüpfung von Job-Status und Fachdaten innerhalb einer einzigen, lokalen ACID-Transaktion ohne verteiltes Konsensprotokoll zu garantieren

Obwohl das kontinuierliche Abfragen eines solchen externen Datenspeichers im Vergleich zu rein lokalen Hauptspeicher-Lösungen Latenzen erzeugt, existiert in der verteilten Architektur kein universeller Idealzustand. Die Wahl des Zustandsspeichers ist stets ein bewusster Trade-off zwischen maximalem Nachrichtendurchsatz und strikten Garantien zur Fehlerbehebung (Kleppmann 2017, Kap. 11, Abschnitt „Rebuilding state after a failure“).

Das Führen eines expliziten Zustandsmodells (z. B. *queued*, *running*) in einer persistenten Datenbank ermöglicht es einer neuen oder neu gestarteten Worker-Instanz, den letzten konsistenten Zustand nach einem Teilausfall direkt auszulesen und die Verarbeitung ohne Datenverlust wiederaufzunehmen.

Um eine Ressourcenerschöpfung durch langlaufende Datenbank-Transaktionen zu ver-

hindern, wird die physische Datenbanksperre auf der Datenbankebene zeitlich von der eigentlichen Job-Ausführung entkoppelt. Ein Worker nutzt einen exklusiven Sperrmechanismus (wie FOR UPDATE SKIP LOCKED) lediglich für die Millisekunden der atomaren Zustandsänderung eines Jobs von *queued* auf *running*. Sofort nach dem Schreiben des neuen Status wird diese isolierte Datenbank-Transaktion geschlossen und die Zeilensperre freigegeben. Die eigentliche, zeitintensive Fachlogik wird anschließend außerhalb einer offenen Transaktion verarbeitet, während das persistente Zustandsmodell im Datenspeicher parallele Zugriffe anderer Worker verhindert (vgl. Kleppmann 2017, Kap. 11).

Ein naiver Ansatz zur Absicherung eines Hintergrundjobs bestünde darin, die Transaktionsgrenze über den gesamten Lebenszyklus der Job-Ausführung zu spannen. Dies bedeutet, dass eine Transaktion geöffnet wird, sobald ein Worker eine Aufgabe akquiriert, und erst schließt, wenn die vollständige Fachlogik abgearbeitet wurde. In produktiven Systemen führt dieses Vorgehen jedoch zu dem Phänomen der langlaufenden Transaktionen (Long-Running Transactions), welche die Resilienz des Gesamtsystems massiv gefährden. Da Hintergrundprozesse definitionsgemäß zeitintensive oder ressourcenintensive Berechnungen sowie E/A-Operationen kapseln (vgl. Kleppmann 2017, Kap. 10), würde eine offene Transaktion über diesen gesamten Zeitraum hinweg die zugewiesene Datenbankverbindung blockieren. Da relationale Datenbanksysteme wie PostgreSQL Verbindungen über einen limitierten Pool (*Connection Pool*) verwalten, führt eine langanhaltende Belegung durch wenige Worker-Instanzen unweigerlich zur Erschöpfung dieser Ressource (*Connection Starvation*). Infolgedessen können synchrone Endpunkte, die für schnelle Client-Anfragen ebenfalls Verbindungen aus diesem Pool benötigen, keine Datenbankinteraktionen mehr durchführen, was zu weitreichenden Timeouts und einem Systemausfall führt (vgl. Kleppmann 2017, Kap. 7).

Die Transaktionsgrenzen müssen so eng wie möglich gefasst werden, was zu einem dreiphasigen Kontrollfluss im Worker führt:

1. **Phase 1 (Gekapselte Statussynchronisation):** Der Worker öffnet eine dedizierte, extrem kurzlaufende Transaktion. Innerhalb dieser Grenze wird ein freier Job gesucht, über Sperrverfahren geschützt und dessen Status im Job-Store atomar von *queued* auf *running* aktualisiert. Unmittelbar nach dem Schreiben des Status wird die Transaktion committet und die Verbindung an den Pool zurückgegeben.
2. **Phase 2 (Transaktionsfreie Fachlogik):** Die eigentliche Verarbeitung des Jobs (z. B. das Generieren eines Reports oder der Aufruf einer externen HTTP-Schnittstelle) erfolgt vollständig außerhalb einer offenen Datenbanktransaktion. Das persistente Zustandsmodell im Speicher verhindert in dieser Phase, dass parallele Worker Zugriff auf denselben Job erhalten (vgl. Kleppmann 2017, Kap. 11).
3. **Phase 3 (Gekapselte Abschlussquittierung):** Nach erfolgreicher Beendigung oder nach einem kontrollierten Abbruch der Fachlogik öffnet der Worker eine zweite, separate Kurzzeittransaktion, um den finalen Endzustand (z. B. *success* oder *failed*) in den Job-Store zu schreiben und sofort zu committen.

erläutern, wieso pessimistisches Locking anstatt von optimistischen verfahren -> Für die atomare Reservierung von Jobs ist ein pessimistisches Verfahren vorteilhaft, da konkurrierende Zugriffe bereits zum Zeitpunkt der Jobauswahl verhindert werden können. Dadurch lässt sich sicherstellen, dass ein Job nur von einer Worker-Instanz gleichzeitig verarbeitet wird. It performs badly if there is high contention (many transactions trying to access the same objects), as this leads to a high proportion of transactions needing to abort. If the system is already close to its maximum throughput, the additional transaction load from retried transactions can make performance worse." (Kleppmann 2017, Kap. 7 Abschnitt „Pessimistic versus optimistic concurrency control“)

5.2 Implementierung

5.2.1 Technologie-Stack

5.2.2 Zentrale Code-Entscheidungen

6 Evaluation

6.1 Fehlerszenarien

6.2 Durchführung

6.3 Ergebnisse

7 Diskussion

7.1 Gewonnene Erkenntnisse

7.2 Einschränkungen und Grenzen der Arbeit

Diese Arbeit betrachtet die Fehlertoleranz ab dem Zeitpunkt, zu dem ein Job persistent im Job-Store vorliegt; die zuverlässige Auftragserzeugung/Client-Kommunikation (z.B. Outbox, Messaging) ist nicht Gegenstand. Consumers may crash at any time, so it could happen that a broker delivers a message to a consumer but the consumer never processes it, or only partially processes it before crashing. In order to ensure that the message is not lost, message brokers use *acknowledgments*: a client must explicitly tell the broker when it has finished processing a message so that the broker can remove it from the queue." (Kleppmann 2017, Kap.11 -> Acknowledgments and redelivery bzw. Message brokers)

REST hat keinen Puffer und ist synchron -> Client und Server muss während der ganzen Kommunikation laufen, damit Kommunikation funktioniert. Weitere Nachteile in Referenc: (Richardson 2018, Kap.3.2.2)

Kein Fokus auf Kommunikation im allgemeinen, weder wie oben genannt die Erstellung von Jobs, als auch die Benachrichtigung bei Fertigstellung. Dafür bräuchte es Transaktionales messaging bspw. mittels transactional outbox pattern (Richardson 2018, Kap.3.3.7) oder asynchrones Messaging (Richardson 2018, Kap.3.4.2)

Es gibt keine perfekte reliability (Kleppmann 2017, Kap. 1, Abschnitt „Reliability“)

Load Leveling umgesetzt?

Performance von DB gegenüber Message Queues

Keine Fehlertoleranz in Bezug auf Datenbeständigkeit (z.B. Festplatte des Job-Stores geht kaputt), Naturkatastrophen (Ganzer Standort fällt aus z.B. wegen Überschwemmung) (Newman 2026, Kap. 9)

Es gibt keine Möglichkeit absolute Garantien zu geben, nur viele Möglichkeiten der Risikoreduktion (Kleppmann 2017, Kap. 7 Abschnitt „The Meaning of ACID“-> Ende)

8 Fazit und Ausblick

Literaturverzeichnis

- Broadcom Inc. (Hrsg.) (24. Mai 2026). *Spring Boot*. Spring Boot. URL: <https://spring.io/projects/spring-boot> (besucht am 24.05.2026).
- Kleppmann, Martin (2017). *Designing data-intensive applications: the big ideas behind reliable, scalable, and maintainable systems*. First edition. Beijing, [China: O'Reilly.
- Kudraß, Thomas (5. März 2015). *Taschenbuch Datenbanken*. Hrsg. von Kudraß Thomas. Carl Hanser Verlag GmbH & Co. KG. ISBN: 978-3-446-43508-7. DOI: 10.3139/9783446440265.fm. URL: <https://www.hanser-elibrary.com/doi/10.3139/9783446440265.fm> (besucht am 21.06.2026).
- Microsoft Corporation (Hrsg.) (31. März 2026a). *Best Practices for Background Jobs - Azure Architecture Center*. URL: <https://learn.microsoft.com/en-us/azure/architecture/best-practices/background-jobs> (besucht am 17.06.2026).
- (12. Juni 2026b). *Queue-Based Load Leveling Pattern - Azure Architecture Center*. URL: <https://learn.microsoft.com/en-us/azure/architecture/patterns/queue-based-load-leveling> (besucht am 17.06.2026).
- Newman, Sam (Sep. 2026). *Building Resilient Distributed Systems*. O'Reilly. URL: <https://learning.oreilly.com/library/view/building-resilient-distributed/9781098163532/> (besucht am 24.05.2026).
- Richardson, Chris (2018). *Microservices patterns*. Software development. Shelter Island: Manning.
- Saake, Gunter, Andreas Heuer und Kai-Uwe Sattler (Juni 2018). *Datenbanken – Konzepte und Sprachen*. mitp Verlags GmbH & Co KG. ISBN: 978-3-95845-778-2. URL: <https://learning.oreilly.com/library/view/datenbanken-konzepte/9783958457782/> (besucht am 19.06.2026).
- Terracotta Inc. (Hrsg.) (24. Mai 2026). *Quartz Scheduler Documentation*. URL: <https://www.quartz-scheduler.org/documentation/quartz-2.5.x/> (besucht am 24.05.2026).
- The PostgreSQL Global Development Group (Hrsg.) (14. Mai 2026). *PostgreSQL 18.4 Documentation*. PostgreSQL Documentation. URL: <https://www.postgresql.org/docs/18/index.html> (besucht am 21.06.2026).